嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：Olist 巴西电商客户分层与销售预测

学　　院：数据科学学院

专业班级：大数据 241

学　　号：20244599851004

姓　　名：黄丹彤

完成日期：2026 年 11 月

组员分工：独立完成（黄丹彤）

数 据 科 学 学 院

Olist 巴西电商客户分层与销售预测

黄丹彤

（嘉兴大学 数据科学学院）

摘　要

本文以 Olist 电商数据集为对象，基于 2016—2018 年的 99,441 个订单与 112,650 条商品明细，构建从获取、清洗、建模到可视化大屏的端到端分析链路。使用 RFM 八分层、同期群留存、ABC/Pareto、波士顿矩阵与 ARIMA 预测，识别客户价值、复购规律、品类贡献和销售趋势；复现教材 15 张模板图、绘制 10 张业务图并搭建 Streamlit 大屏。研究发现：47.5% 的高价值客户贡献 78% 的 GMV，首月留存仅 0.44%，25.9% 的商品贡献 80% 的 GMV，ARIMA 回测 MAPE 为 5.59%。研究可为电商运营与销售预测提供参考。

关键词：电商数据分析；RFM 模型；同期群分析；SARIMA；可视化大屏

1 引言

本章介绍研究背景、研究目的与研究意义，说明为什么选择 Olist 巴西电商数据，以及本项目要回答的核心商业问题。

1.1 研究背景

近年来，巴西电商市场保持较快增长，Olist 作为连接中小卖家与消费者的平台，积累了订单、支付、物流、评价等多维数据。电商企业并不缺数据，缺的是把数据转化为可执行策略的能力:哪些客户贡献主要 GMV、哪些品类值得投入、复购为什么低、未来几个月销量如何。与此同时，课程要求将《Excel 数据可视化——从图表到数据大屏》中的图表模板与 Python 商业分析模型结合，形成可复现的端到端项目，这为本文提供了明确的实践场景。

1.2 研究目的

本文旨在构建一条从公开数据获取、清洗治理、商业建模到可视化大屏的完整链路，回答四个问题：谁在买（RFM）、会不会复购（同期群）、卖什么（ABC 与波士顿矩阵）、未来卖多少（SARIMA），并用 Python 复现教材图表、搭建交互式大屏，使分析结论能够被业务人员直接使用。

1.3 研究意义

实践上，为中小电商提供低成本、可复现的客户与品类分析框架；方法上，将描述性分析（RFM、ABC、波士顿矩阵）与预测性分析（SARIMA）结合，避免只做静态报表；教学上，展示从 Excel 模板到 Python 可视化大屏的迁移路径，体现“数据获取—清洗—建模—可视化—洞察”的完整商业分析流程。

2 数据准备与预处理

本章说明数据来源、合规获取方式、数据集结构以及清洗治理过程，为后续建模提供可复现的数据基础。

2.1 数据源介绍

数据来自 Kaggle 公开数据集 Brazilian E-Commerce Public Dataset by Olist，覆盖 2016-09-04 至 2018-10-17 的 99,441 个订单、112,650 条商品明细、99,224 条评价，共 9 张表。数据包含订单状态、客户、商品、卖家、支付、评价、物流时间与地理坐标，能够支撑多表关联、客户分层、品类分析和时间序列预测。

表 1 数据表结构

表名	行数	粒度	主键
orders	99,441	一行一个订单	order_id
order_items	112,650	一行一个订单商品	order_id + order_item_id
payments	103,886	一行一笔支付	order_id + payment_sequential
reviews	99,224	一行一条评价	review_id（需校验）
customers	99,441	一行一个订单客户	customer_id
products	32,951	一行一个商品	product_id
sellers	3,095	一行一个卖家	seller_id
geolocation	1,000,163	一行一个邮编坐标	无唯一键
category_translation	71	一行一个品类翻译	product_category_name

2.2 合规获取方式

本项目使用 Kaggle 官方数据集 API 获取数据，属于课程允许的“官方下载文件 / 官方数据接口”方式。该接口对公开数据集返回 302 跳转到 Google Storage 的签名地址，脚本使用 Python 标准库 urllib 跟随跳转，没有编写或使用任何网页爬虫。下载脚本内置 SHA256 校验（967e41e04fc306fe604e2a693f488995a8b41e5047418f8a5c8e4abd6deca784），保证文件完整、可复现。

2.3 数据来源合规声明

数据集采用 CC BY-NC-SA 4.0 许可，仅用于课程作业与学术研究，需署名、非商业使用并以相同方式共享。原始数据体积较大且受许可约束，因此不提交到公开仓库；仓库只保留下载脚本、校验信息与数据处理代码，任何人克隆仓库后运行下载脚本即可复现。

2.4 数据集概述

orders 为主表，通过 customer_id 关联 customers，通过 order_id 关联 order_items、payments、reviews;order_items 通过 product_id、seller_id 关联 products、sellers;products.product_category_name 关联品类翻译表。主外键检查显示 orders→customers、items→orders/products/sellers、payments/reviews→orders 的命中率均为 100%。99,441 个订单中有 98,666 个含商品明细，775 个无明细，主要为取消或不可用订单。

3 数据清洗与治理

本章说明缺失值、异常值、重复值、类型统一、指标派生与多表整合的处理规则。

3.1 数据清洗

时间字段统一转换为 datetime；邮编前缀按字符串读取并补足 5 位，避免 01037 被解析为 1037；商品品类缺失标记为 unknown，重量与长宽高缺失用中位数填充并增加 has_dimensions 标记；评价按订单取最新一条，review_id 重复的记录保留并加标记；地理表按邮编前缀聚合，经纬度取中位数，1,000,163 行压缩为 19,015 行。

3.2 数据转换

派生 purchase_month 、 delivery_days 、 late_days 、 is_late 、 approval_hours、product_volume_cm3、item_count、gmv 等指标。is_late 仅在“实际送达时间”和“承诺送达时间”均存在时计算，避免把缺失值误判为准时；金额类指标统一为 BRL。

3.3 数据整合

生成订单级宽表 orders_enriched（99,441 行 × 36 列），整合商品、支付、评价、客户信息；导出 CSV 与带索引的 SQLite 数据库。本项目使用全量数据，不做抽样；所有随机过程固定 RANDOM_SEED = 42，保证结果可复现。

4 商业分析模型

本章介绍模型选型、参数与阈值依据，以及各模型的计算结果与验证指标。

4.1 模型选型

选取 5 个核心模型和 1 个辅助分析：RFM 客户价值分层、同期群留存、ABC/Pareto 商品分类、波士顿矩阵品类投入、SARIMA 月度 GMV 预测，以及订单转化漏斗。RFM 回答“谁贡献了 GMV”，同期群回答“客户会不会复购”，ABC 与波士顿矩阵回答“哪些商品/品类值得投入”，SARIMA 回答“未来卖多少”，漏斗回答“履约链路是否稳定”。

4.2 参数与阈值设定依据

RFM 以 customer_unique_id 为客户唯一标识，快照日为 2018-09-04；R 与 M 用中位数切分（R 中位数 225 天，M 中位数 R$89.89），F 中位数为 1，因此以 F≥2 作为复购阈值。选用中位数而非均值，是因为 GMV 右偏严重，均值会被少数大客户拉高。ABC 以累计 GMV 80%/95% 作为 A/B/C 边界。波士顿矩阵同比统一取 2017 年 1—8 月 vs 2018 年 1—8 月，避免 2018 年数据不完整；以份额中位数 0.49%、增长率中位数 188% 划分四象限。SARIMA 使用 2017-01—2018-08 共 20 个月，前 14 个月训练、后 6 个月回测，按回测 RMSE 选择模型。

4.3 模型计算与验证

RFM 将 94,983 位客户分为 8 类。重要发展客户 22,704 人（23.90%）贡献 39.08% GMV，重要挽留客户 22,385 人（23.57%）贡献 38.93%，两者合计 47.5% 的客户贡献 78.0% 的 GMV；重要价值/保持客户仅 2,403 人，但平均订单数约 2.1，是复购核心。表 2 给出八分层结果，图 17 为对应的 GMV 贡献图。

表 2 RFM 八分层结果

分层	客户数	客户占比	GMV 占比
重要发展客户	22,704	23.90%	39.08%
重要挽留客户	22,385	23.57%	38.93%
一般挽留客户	23,683	24.93%	8.29%
一般发展客户	23,324	24.56%	8.14%
重要价值客户	1,340	1.41%	2.98%

分层	客户数	客户占比	GMV 占比
重要保持客户	1,063	1.12%	2.36%
一般价值客户	243	0.26%	0.11%
一般保持客户	241	0.25%	0.11%

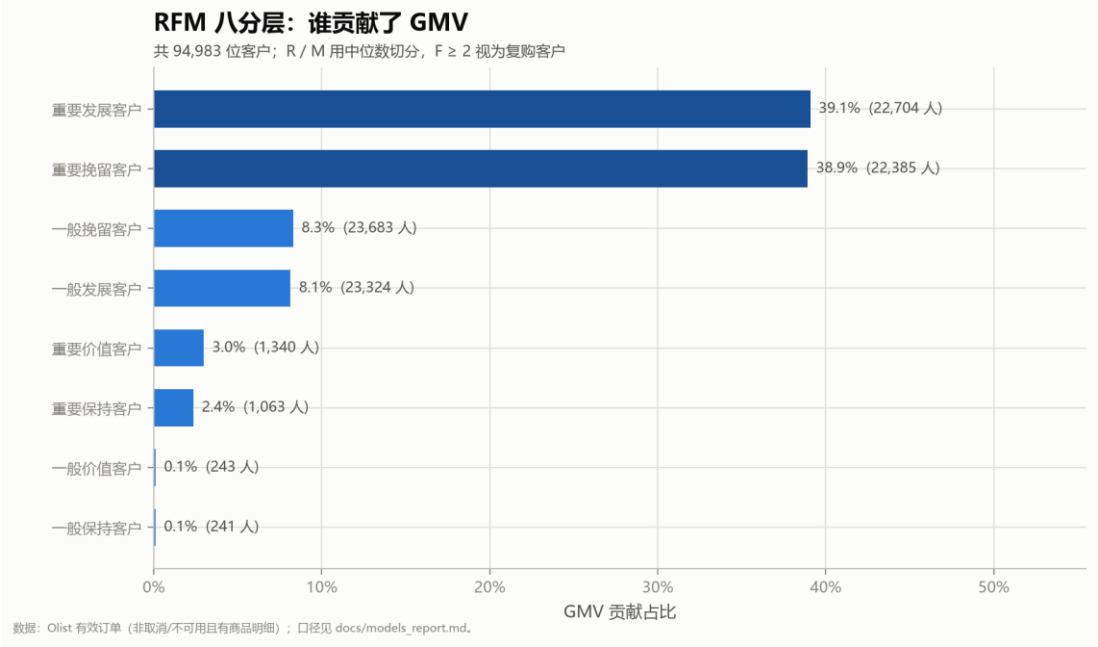


图 17 RFM 八分层 GMV 贡献

同期群分析共识别 23 个首购月同期群，其中 21 个样本量≥30。第 1 月平均留存 0.44%，第 3 月 0.21%，第 6 月 0.19%，说明 Olist 的复购率极低，增长主要依赖新客。图 18 为同期群留存热力图。

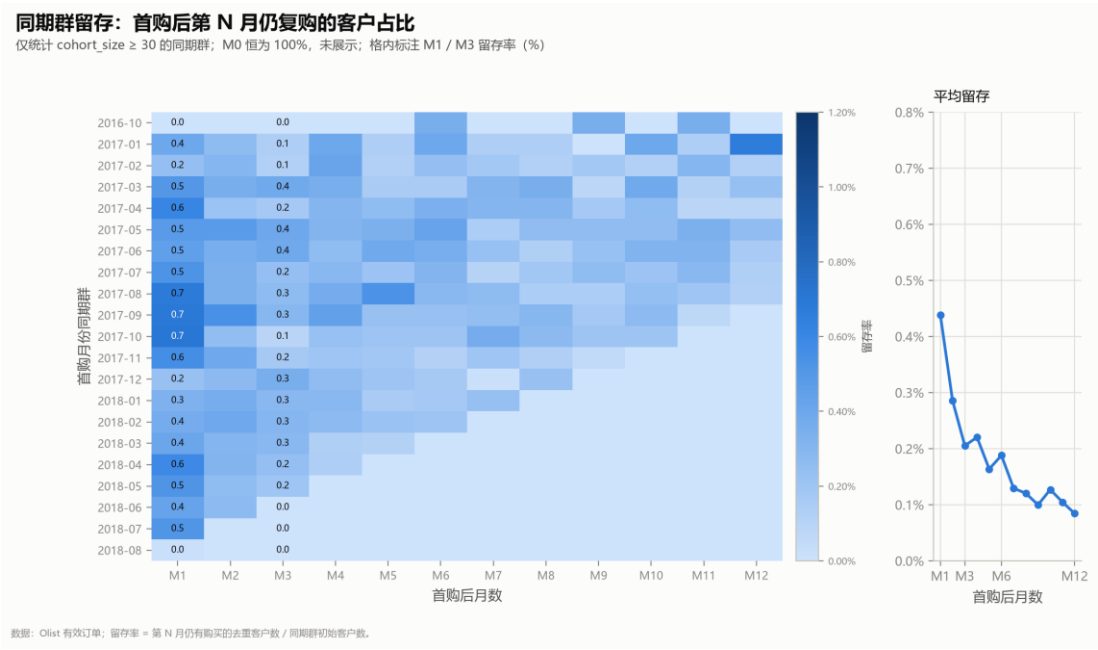


图 18 同期群留存热力图

ABC 分类中，A 类 8,478 个商品（25.9%）贡献 80.00% GMV；B 类 11,226 个（34.3%）贡献 15.00%；C 类 13,025 个（39.8%）贡献 5.00%。前 20 个单品仅贡献 5.4%，说明 A 类是一个“长尾中的头部集合”，不能只盯少数爆款。表 3 与图 19 给出分类结果。

表 3 ABC 分类结果

类别	商品数	商品占比	GMV 占比
A	8,478	25.90%	80.00%
B	11,226	34.30%	15.00%
C	13,025	39.80%	5.00%

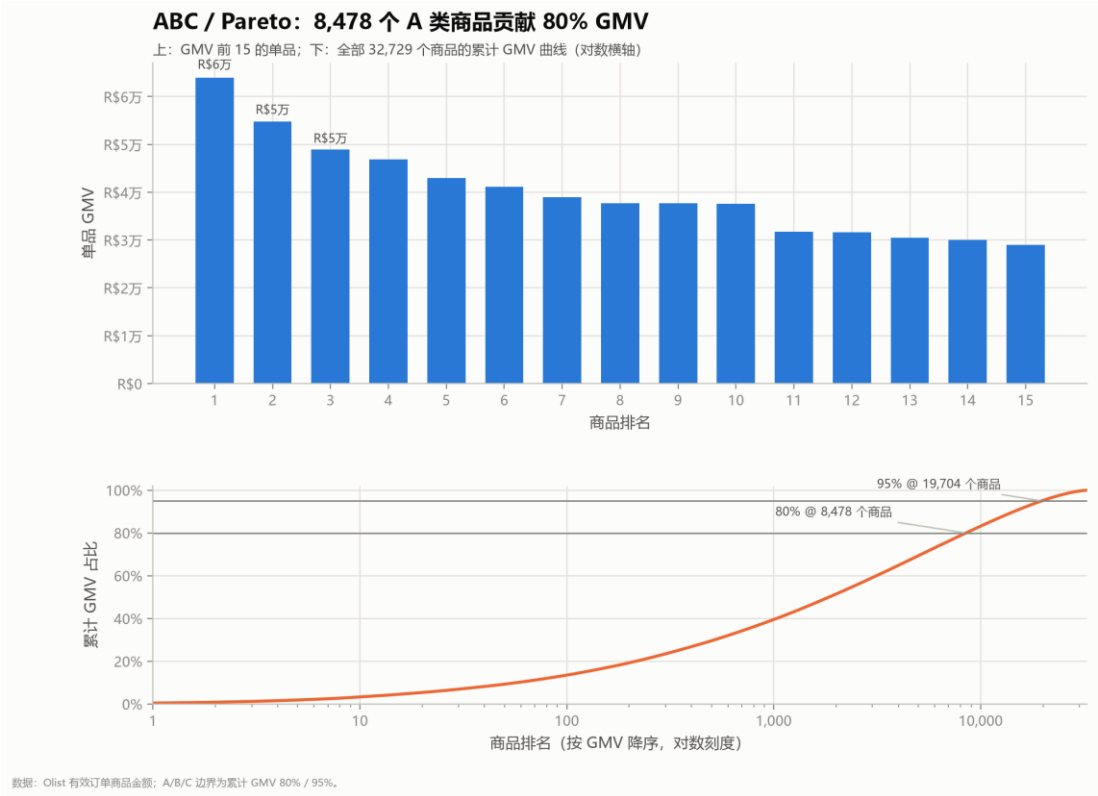


图 19 ABC/Pareto 图

波士顿矩阵共有 63 个品类参与划分：明星 15 个（health_beauty、watches_gifts、housewares、baby、telephony 等），现金牛 17 个（bed_bath_table、sports_leisure、computers_accessories 等），问题 17 个，瘦狗 14 个。表 4 给出象限分布，图 20 为四象限气泡图。

表 4 波士顿矩阵象限分布

象限	品类数	代表品类
明星（高份额/高增长）	15	health_beauty、watches_gifts、housewares、baby
现金牛（高份额/低增长）	17	bed_bath_table、sports_leisure、computers_accessories
问题（低份额/高增长）	17	需结合利润率与复购判断
瘦狗（低份额/低增长）	14	考虑收缩 SKU

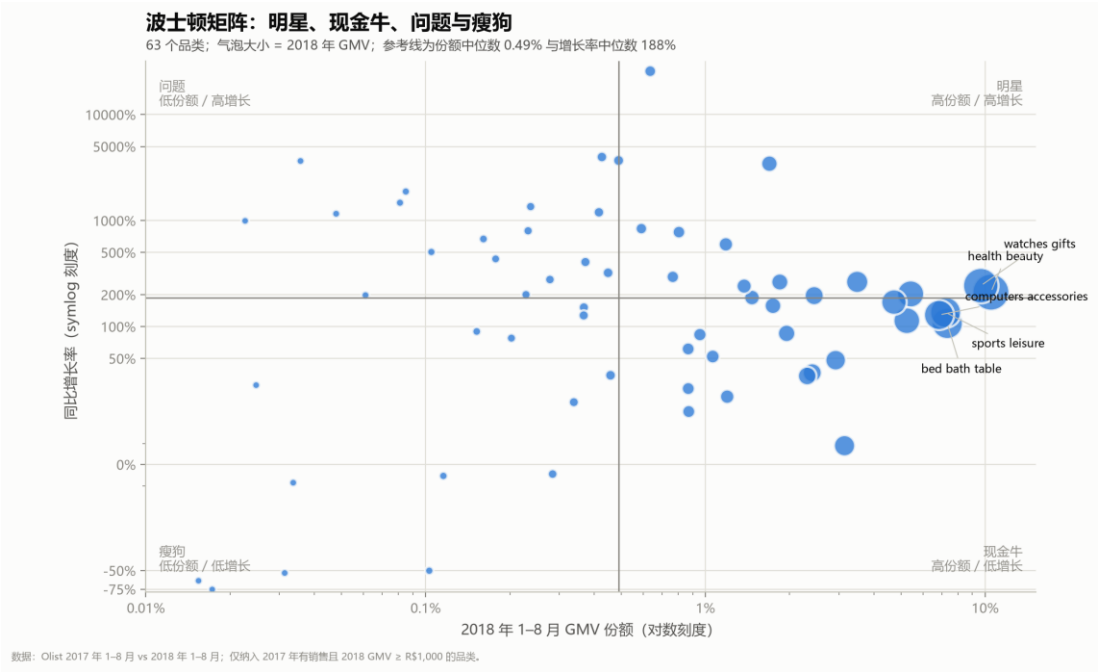


图 20 波士顿矩阵

SARIMA 部分比较了 ARIMA(1,1,1)、ARIMA(0,1,1) 与多个 SARIMA 候选。季节差分模型因月度样本仅 20 个月而失败，最终按回测 RMSE 选择 ARIMA(1,1,1)：RMSE 67,582，MAPE 5.59%，显著优于季节朴素基准（MAPE 50.56%）。未来 6 个月预测均值约 R$861,872/月，并给出 95% 置信区间。表 5 与图 16 为模型比较与预测结果。

表 5 SARIMA 候选模型回测结果

模型	RMSE（R$）	MAPE
ARIMA(1,1,1)	67,582	5.59%
ARIMA(0,1,1)	94,807	7.43%
SARIMA(1,1,1)(1,0,1,12)	75,152	6.04%
SARIMA(0,1,1)(0,0,1,12)	114,698	9.88%
季节朴素基准	489,873	50.56%

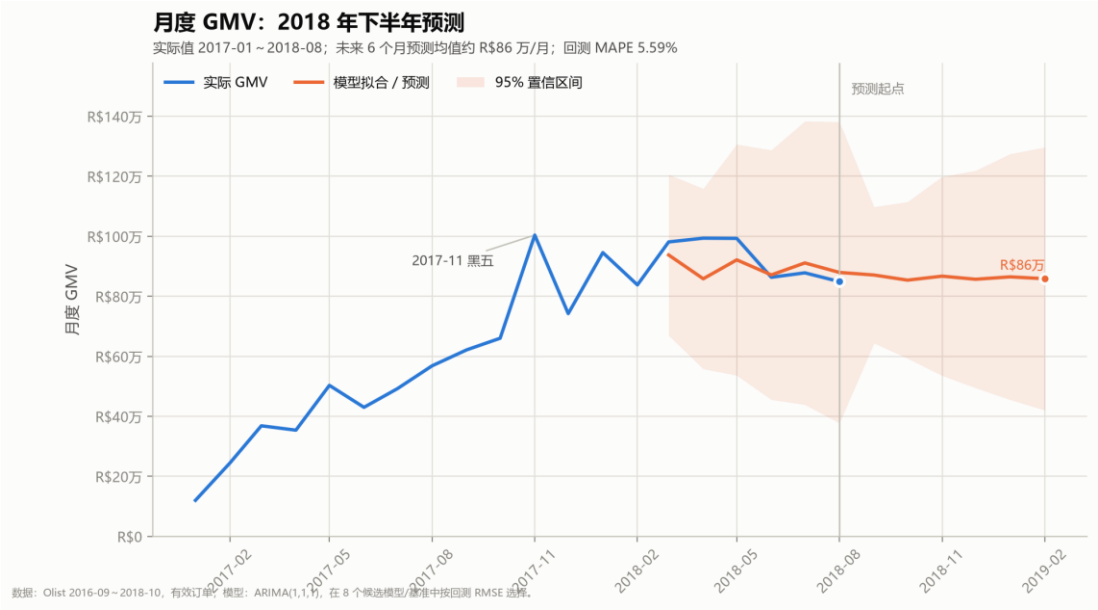


图 16 月度 GMV 与六个月预测

订单转化漏斗为：下单 99,441 → 支付通过 99,281 → 发货 97,658 → 送达 96,476，总体送达率 97.0%。主要损失来自取消/不可用订单，支付与发货环节损失较小。表 6 与图 25 给出漏斗结果。

表 6 订单转化漏斗

阶段	订单数	占下单	较上一阶段
下单	99,441	100.0%	—
支付通过	99,281	99.8%	99.8%
发货	97,658	98.2%	98.4%
送达	96,476	97.0%	98.8%

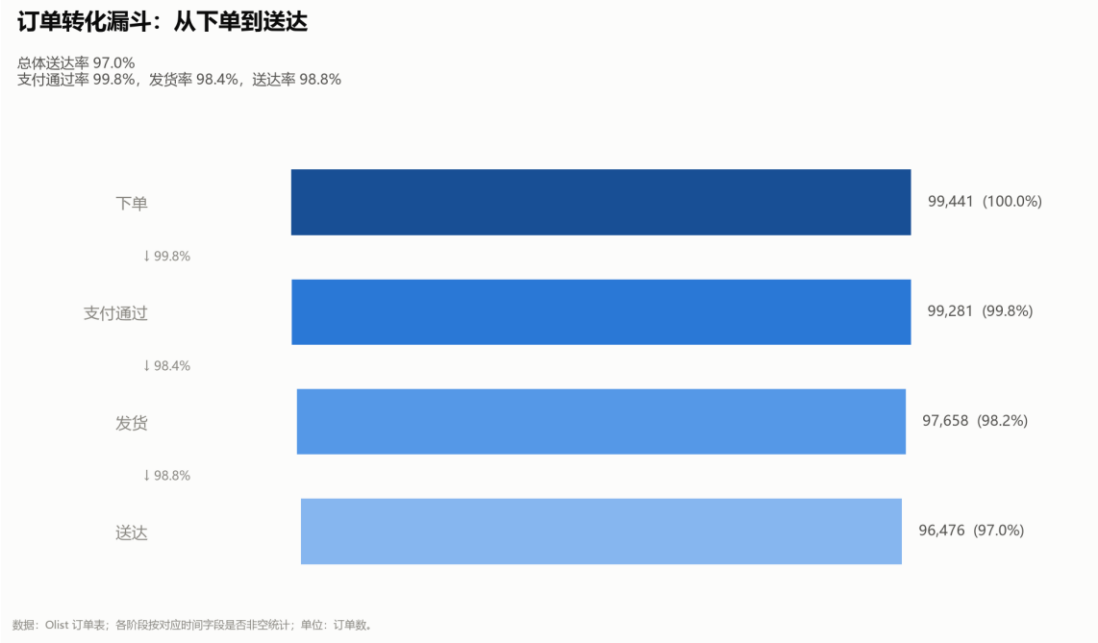


图 25 订单转化漏斗

5 Python 数据分析与可视化

本章展示探索性分析、教材模板复现、业务模型图与交互式大屏的实现与结果。

5.1 数据探索性分析

数据体检显示：订单表缺失率 0.62%，评价表缺失率 21.01%（主要是评论正文），商品表缺失率 0.83%，地理表无缺失但有 261,831 条全行重复。GMV 合计 R$13,591,643.70，运费合计 R$2,251,909.54；支付金额与“商品金额+运费”的平均绝对差仅 R$0.03，说明支付与订单明细一致性良好。有效订单（非取消/不可用且有商品明细）共 98,199 个。

5.2 可视化模板复现

复现教材第二章前 15 套模板：渐变柱形、带均值柱形、渐变圆角柱形、标注柱形、层叠柱形、蝴蝶图、REPT 蝴蝶、数值百分比、对比柱形、甘特图、平滑折线、菱形走势、对比折线、单值圆环、水球图。方法是从 xlsx 的 chart XML 解析颜色、字号、渐变、布局与标注位置，用 matplotlib 逐像素还原；15 张图平均通道误差 1.61—5.76/255，像素一致率 87.42%—96.43%，交付图为 200 dpi。图 1、图 5、图 8、图 10、图 14 为代表性示例，完整 15 张见附录 C。

与 Excel 实现相比，Python 方案把配色、字号、渐变和标注位置写成可复用参数：Excel 模板依赖手工拖拽和逐图调整，换一批数据就要重新排版；本项目从工作簿的 chart XML 读取颜色、渐变与布局，用 matplotlib 还原后，同一脚本可批量换数出图，并直接导出 200 dpi 位图和矢量图。代价是前期解析 XML、调试中文字体的成本更高，但可复现性和批量生产能力明显更强；对于联动筛选与下钻，Excel 静态图无法实现，而 Streamlit 大屏可以通过筛选器实时联动。



图 1 渐变柱形图（模板复现）

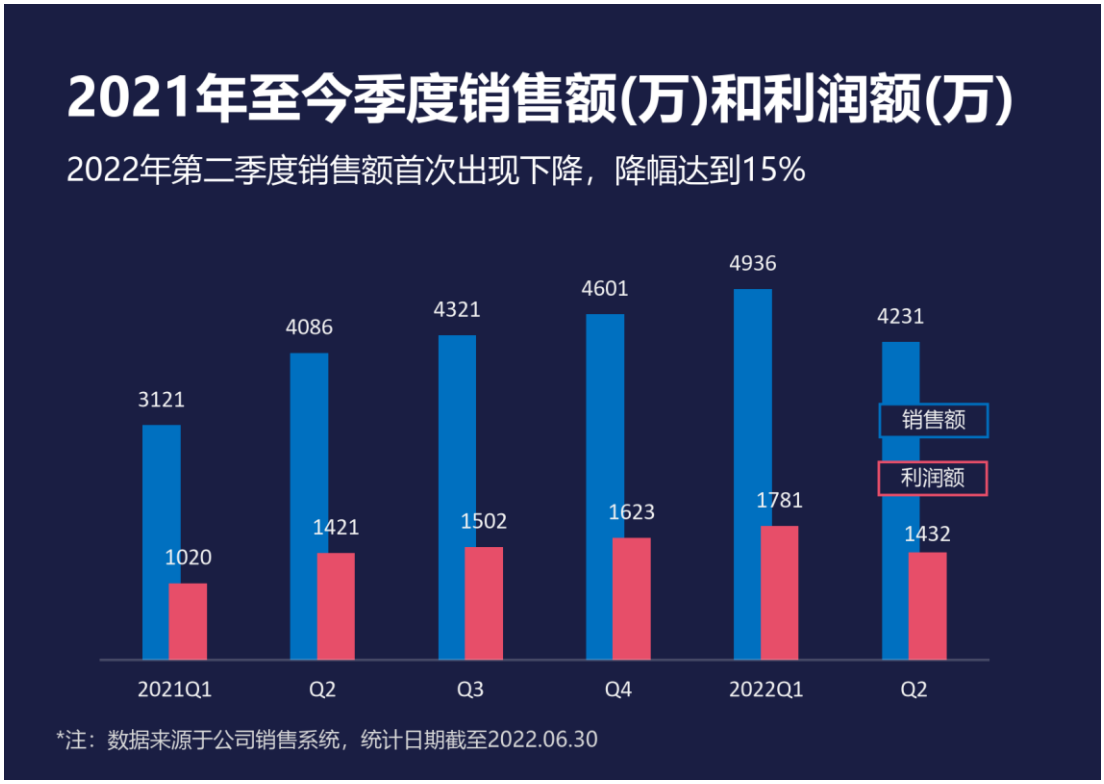


图 5 层叠柱形图（模板复现）

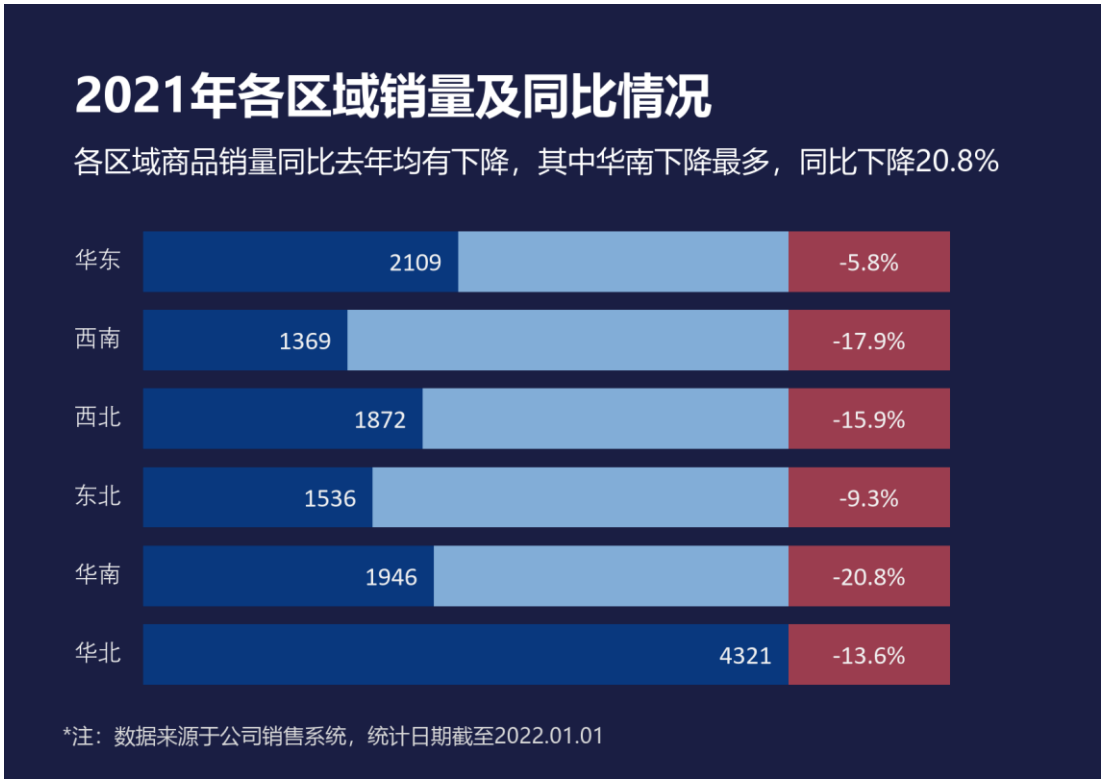


图 8 数值百分比（模板复现）

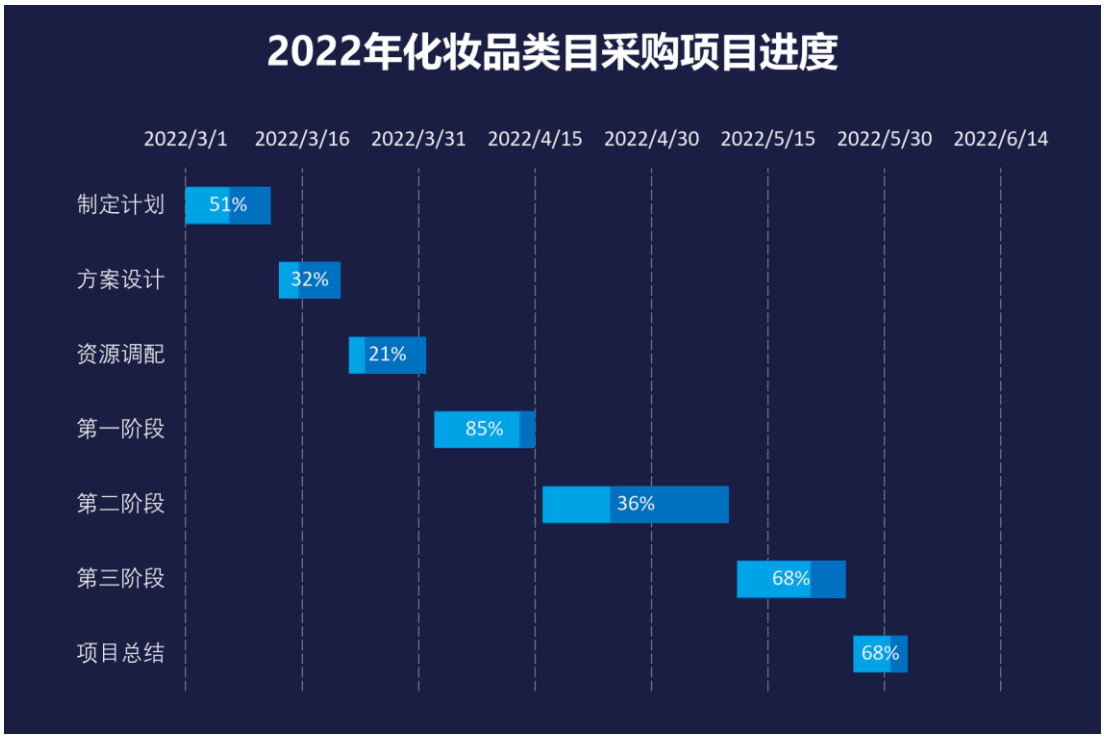


图 10 甘特图（模板复现）



图 14 单值圆环图（模板复现）

5.3 业务模型图

10 张业务图与模型一一对应：图 16 月度 GMV 与预测、图 17 RFM、图 18 同期群、图 19 ABC、图 20 波士顿、图 21 品类 Top 15、图 22 配送延迟与评分、图 23 支付方式、图 24 RFM 气泡散点、图 25 订单漏斗。前文已展示图 16—20 与图 25，这里补充图 21—24。

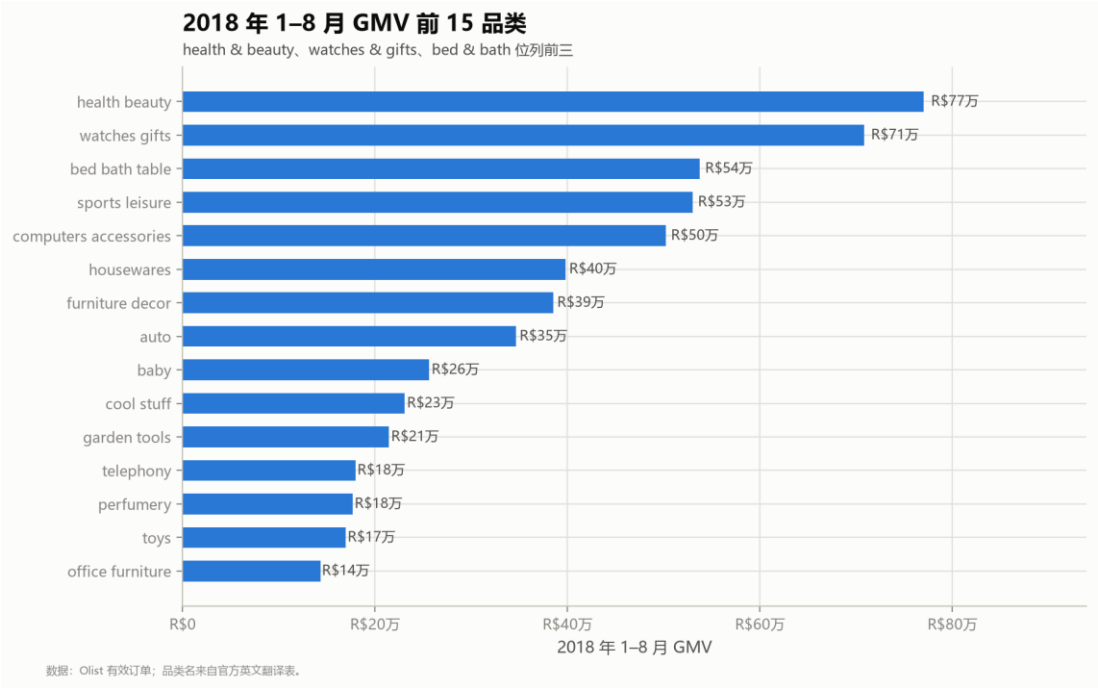


图 21 2018 年 1—8 月 GMV 前 15 品类

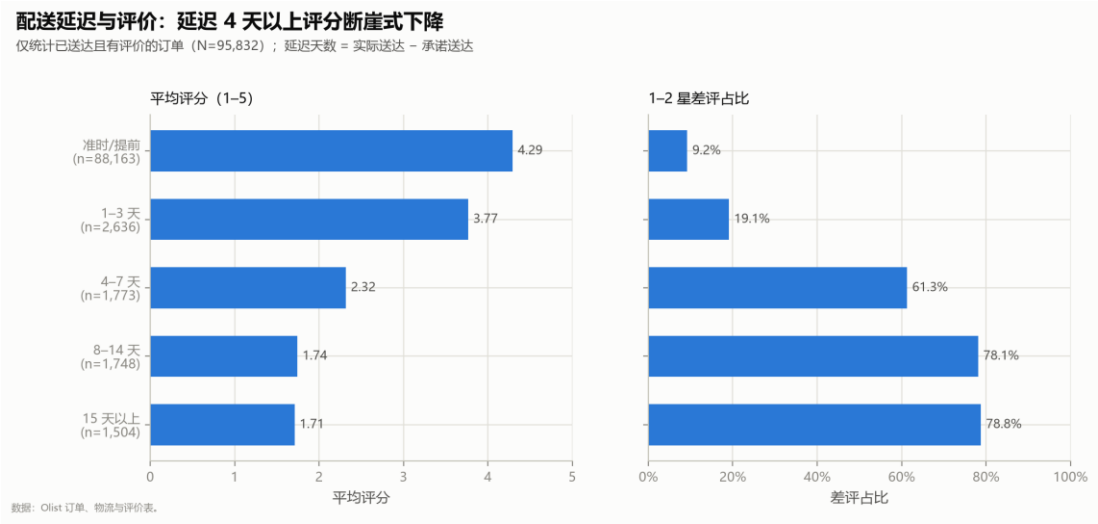


图 22 配送延迟与评价

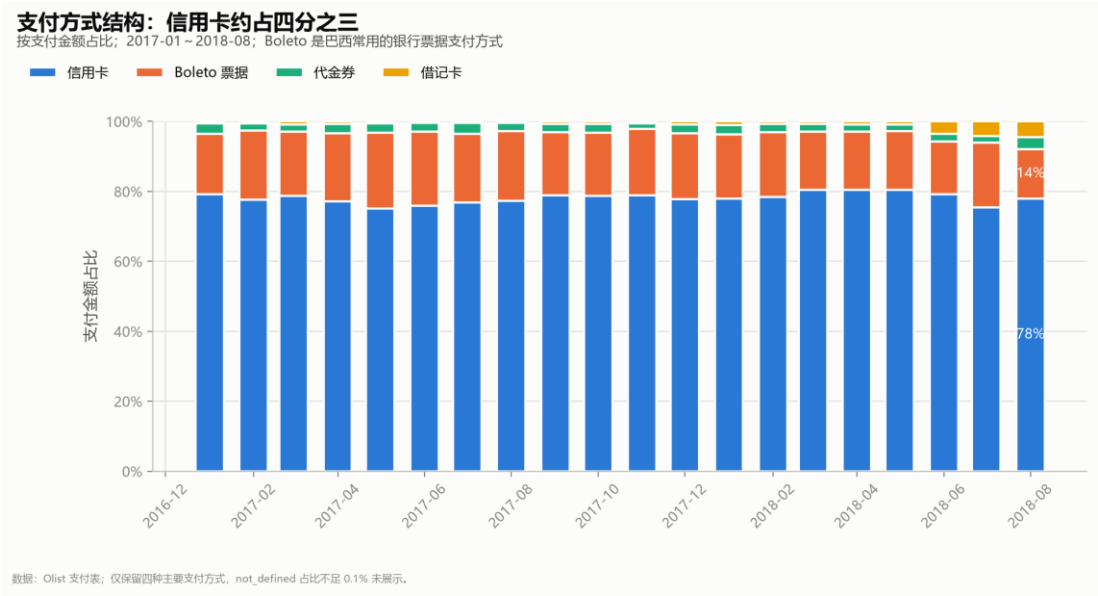


图 23 支付方式结构

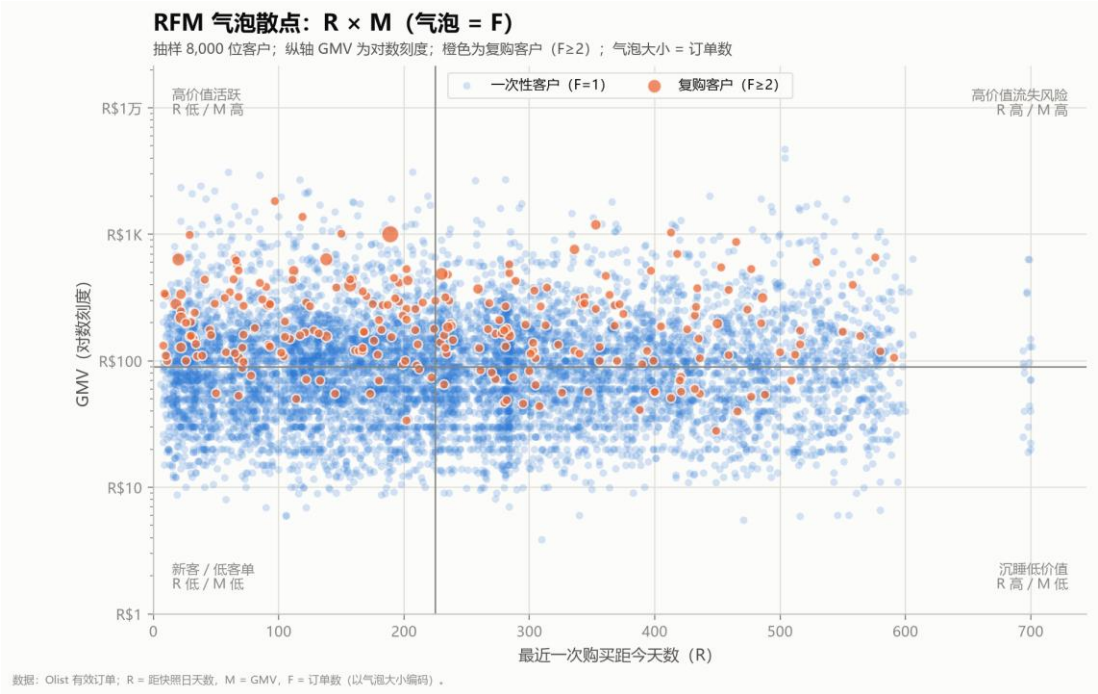


图 24 RFM 气泡散点

5.4 交互式可视化大屏

使用 Streamlit + Plotly 搭建交互式大屏，包含 5 个 KPI（GMV、订单数、客户数、客单价、延迟送达率）、4 个页签（经营总览、客户与留存、品类与预测、数据明细）、日期/州/品类/订单状态筛选、明细表与 CSV 下载。RFM、同期群、波士顿矩阵、SARIMA 为离线全量结果，其余图表随筛选联动。运行命

令为 streamlit run scripts/06_dashboard.py，默认地址 http://localhost:8501。图 26 为大屏截图。

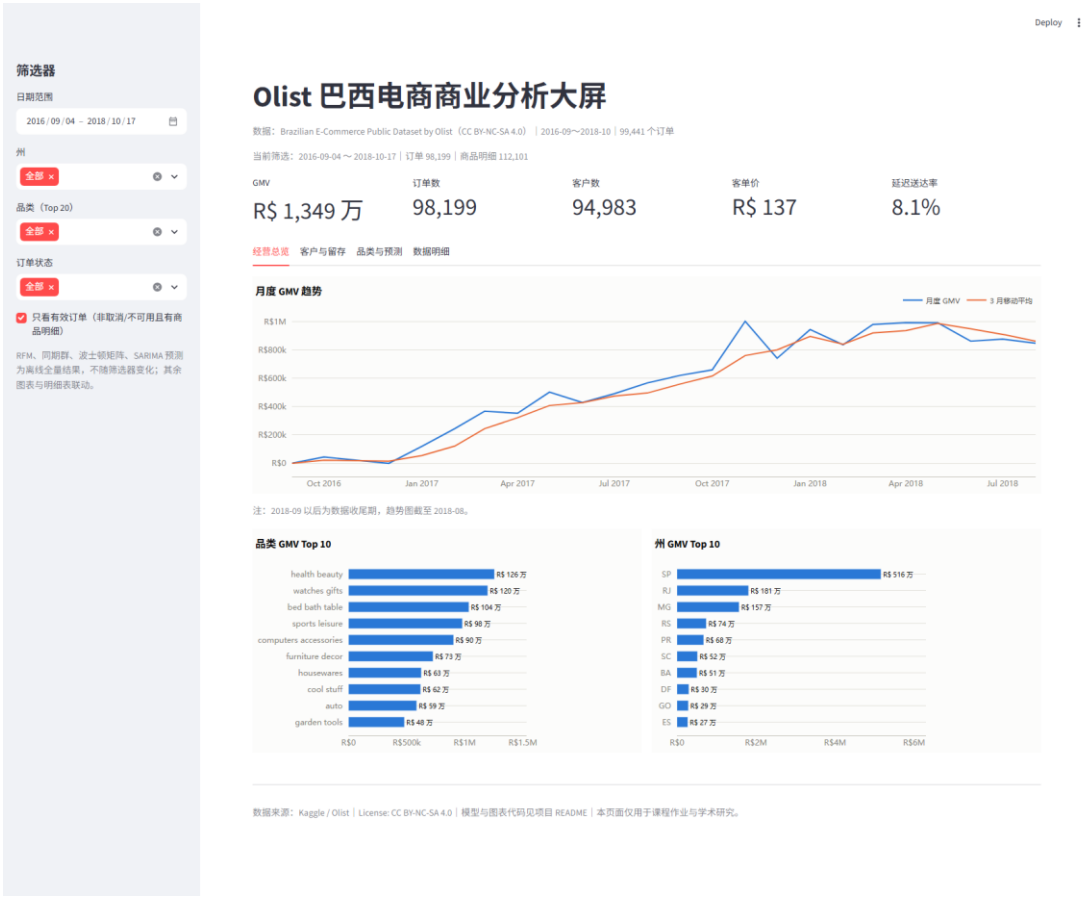


图 26 Streamlit 交互式大屏

6 商业案例分析

本章结合模型结果给出商业解读与可执行建议。

6.1 案例背景

Olist 连接巴西中小卖家与消费者，2016—2018 年处于快速增长期。平台的核心问题是客户复购率低、品类分散、物流时效差异大，需要通过数据分析识别高价值客户、核心品类与履约短板。

6.2 结果解读

第一，客户高度集中：47.5% 的高价值客户贡献 78.0% GMV，其中“重要挽留”客户平均 R 约 372 天，存在明显流失风险。第二，复购率低：第 1 月留存仅 0.44%，第 6 月 0.19%，增长主要依赖新客。第三，商品贡献高度集中：25.9% 的商品贡献 80% GMV，但前 20 个单品仅贡献 5.4%，说明 A 类商品数

量多、长尾明显。第四，品类分化：15 个明星品类、17 个现金牛、17 个问题、14 个瘦狗。第五，物流是体验分水岭：准时/提前订单平均评分 4.29，4—7 天降至 2.32，15 天以上仅 1.71，差评率 78.8%。第六，支付以信用卡（78.5%）和 Boleto（18.0%）为主。第七，未来 6 个月 GMV 预测均值约 R$86 万/月，MAPE 5.59%。

6.3 商业建议

（1）客户分层运营：对“重要挽留”客户做 30/60/90 天召回，对“重要发展”客户发二次购买券，对“重要价值/保持”客户提供会员等级与专属客服。

（2）提升复购：首购后 30 天触发品类交叉推荐，60 天触发免运费券，90 天触发老客专属折扣；按品类复购周期设计触达节奏。

（3）商品与品类策略：A 类商品保库存、保曝光，B 类做组合销售，C 类清理长尾；明星品类加大投放，现金牛维持份额、控制成本，问题品类小步测试，瘦狗品类收缩 SKU。

（4）物流与履约体验：按承运商与州考核时效，对预计延迟订单主动通知与补偿，把承诺送达时间纳入商品页；对取消原因分类（支付失败、库存不可用、客户主动取消），优先修复可运营环节，把履约稳定性纳入承运商与库存考核。

（5）支付、预测与备货：保留 Boleto，优化信用卡分期展示，用代金券做召回与清库存；用预测中值做预算、95% 区间上限做备货与人力弹性，每月滚动更新，避免只按点预测备货。

7 结论与展望

本章总结研究结论、研究局限与后续改进方向，并披露 AI 工具的使用情况。

7.1 研究结论

本文完成了 9 表关联、99,441 个订单的清洗与治理，构建了订单级宽表；使用 RFM、同期群、ABC/Pareto、波士顿矩阵、SARIMA 和订单漏斗六个模型，得到客户集中、复购低、A 类商品贡献 80%、物流延迟显著影响评分、预测 MAPE 5.59% 等结论；复现教材 15 张模板图、绘制 10 张业务图并搭建 Streamlit 大屏，形成了可复现的端到端商业分析项目。

7.2 局限性与展望

研究仍有局限:数据仅覆盖 2016—2018 年,月度样本只有 20 个月,SARIMA 的季节项容易过拟合；数据缺少成本与利润字段，无法计算 CLV 与真实利润；RFM 阈值依赖中位数，换数据后需要重新校准。未来可引入利润与成本数据做客户终身价值分析，用 Prophet、LSTM 与 SARIMA 对比，接入实时数据做在线大屏，并通过 A/B 实验验证运营策略。

7.3 AI 使用披露

本文使用 Claude Code（Anthropic）辅助完成数据下载脚本、清洗流水线、RFM/同期群/ABC/波士顿/SARIMA 代码、matplotlib/Plotly 图表、Streamlit 大屏与论文框架。关键提示词包括“基于 Olist 数据集设计分析流程并说明阈值依据”“用 matplotlib 绘制 10 张业务图，配色使用通过 CVD 校验的调色板”“生成包含 6 个以上联动组件的 Streamlit 大屏”。作者检查了数据许可、字段口径、模型阈值、图表结论与论文表述；所有数字均来自可复现脚本，未使用 AI 编造数据。AI 仅作为辅助工具，论文观点与最终表述由作者负责。

参考文献

[1] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

[2] 郭宏远. Excel 数据可视化——从图表到数据大屏[M]. 北京: 清华大学出版社, 2022.

[3] Hughes A M. Strategic Database Marketing[M]. Chicago: Probus Publishing, 1994.

[4] Chen D, Sain S L, Guo K. Data mining for the online retail industry: A case study of RFM model-based customer segmentation[J]. Journal of Database Marketing & Customer Strategy Management, 2012, 19(3): 197-208.

[5] Box G E P, Jenkins G M, Reinsel G C, et al. Time Series Analysis: Forecasting and Control[M]. 5th ed. Hoboken: Wiley, 2015.

[6] Streamlit. Streamlit Documentation[EB/OL]. https://docs.streamlit.io.

[7] Plotly. Plotly Python Open Source Graphing Library[EB/OL]. https://plotly.com/python/.

附录

A 核心代码片段

```
import pandas as pd
from statsmodels.tsa.statespace.sarimax import SARIMAX
snapshot = valid['purchase_date'].max() + pd.Timedelta(days=1)
rfm = valid.groupby('customer_unique_id').agg(
    last_purchase=('purchase_date', 'max'),
    frequency=('order_id', 'nunique'),
    monetary=('gmv', 'sum'),
)
rfm['recency'] = (snapshot - rfm['last_purchase']).dt.days
model = SARIMAX(train, order=(1, 1, 1), seasonal_order=(0, 0, 0, 0),
                enforce_stationarity=False, enforce_invertibility=False)
fit = model.fit(disp=False)
forecast = fit.get_forecast(steps=6)
```

B Gitee/github 仓库链接与目录结构

仓库链接：https://github.com/HuangDantong/olist-analysis

```
olist-analysis/
├── data/raw/           # 原始数据（git 忽略）
├── data/clean/         # 清洗数据与 SQLite（git 忽略）
├── scripts/            # 00—08 分析脚本
├── outputs/figures/    # 模板图、业务图、大屏截图
├── outputs/tables/     # 模型结果 CSV
├── docs/               # 数据说明、体检/清洗/模型报告、论文
├── requirements.txt
├── run_all.py
└── README.md
```

C 图表索引

表 C1 图表索引

图号	文件	说明
图 1	fig01_渐变柱形图.png	渐变柱形图
图 2	fig02_带均值柱形图.png	带均值柱形图
图 3	fig03_渐变圆角柱形图.png	渐变圆角柱形图
图 4	fig04_标注柱形图.png	标注柱形图
图 5	fig05_层叠柱形图.png	层叠柱形图
图 6	fig06_蝴蝶图.png	蝴蝶图
图 7	fig07_REPT 蝴蝶图.png	REPT 蝴蝶图

图号	文件	说明
图 8	fig08_数值百分比.png	数值百分比
图 9	fig09_对比柱形图.png	对比柱形图
图 10	fig10_甘特图.png	甘特图
图 11	fig11_平滑折线图.png	平滑折线图
图 12	fig12_菱形走势图.png	菱形走势图
图 13	fig13_对比折线图.png	对比折线图
图 14	fig14_单值圆环图.png	单值圆环图
图 15	fig15_水球图.png	水球图
图 16	fig16_月度 GMV 与预测.png	月度 GMV 与六个月预测
图 17	fig17_RFM 分层贡献.png	RFM 八分层 GMV 贡献
图 18	fig18_同期群留存热力图.png	同期群留存热力图
图 19	fig19_ABC 帕累托图.png	ABC/Pareto 图
图 20	fig20_波士顿矩阵.png	波士顿矩阵
图 21	fig21_品类 GMV 前 15.png	2018 年 1—8 月 GMV 前 15 品类
图 22	fig22_配送延迟与评价.png	配送延迟与评价
图 23	fig23_支付方式结构.png	支付方式结构
图 24	fig24_RFM 气泡散点图.png	RFM 气泡散点
图 25	fig25_订单转化漏斗.png	订单转化漏斗
图 26	dashboard_preview.png	Streamlit 交互式大屏

注：模板图位于 outputs/figures/templates/，业务图位于 outputs/figures/business/；以下为 15 张模板复现图缩略图。



图 1 渐变柱形图



图 2 带均值柱形图



图 3 渐变圆角柱形图



图 4 标注柱形图



图 5 层叠柱形图



图 6 蝴蝶图

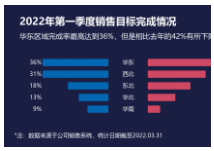


图 7 REPT 蝴蝶图

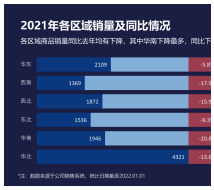


图 8 数值百分比



图 9 对比柱形图



图 10 甘特图

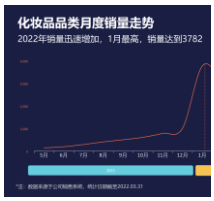


图 11 平滑折线图



图 12 菱形走势图



图 13 对比折线图



图 14 单值圆环图



图 15 水球图